Análise e Desenvolvimento de Sistemas - EAJ/UFRN
TAD0018 - Processamento Digital de Imagens - Turma 01

Limiarização

Antonino Feitosa
antonino.feitosa@ufrn.br
Macaíba, outubro de 2026

Aula Passada

- Fundamentos
- Filtros Espaciais de Aguçamento
- Detecção de Pontos, Linhas e Bordas

Sumário

- Fundamentos
- Limiarização Global Simples
- Método de OTSU
- Limiarização Global Variável

Limiarização

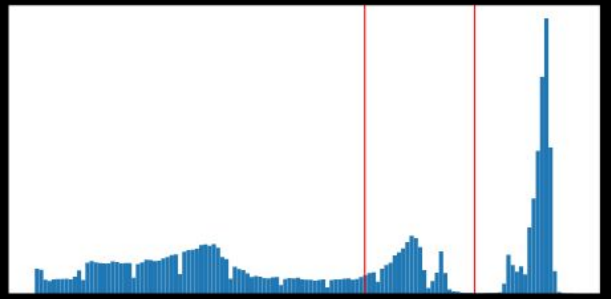
Limiarização

- Limiarização de imagens:

$$g(x,y) = \begin{cases} 1 & \text{se } f(x,y) > T \\ 0 & \text{se } f(x,y) \leq T \end{cases}$$

- Limiarização global: quando T é constante.
- Limiarização variável: quando o valor de T muda ao longo da imagem.
  - Dinâmica ou adaptativa: se T depende das coordenadas espaciais

Limiarização









https://vincmazet.github.io/bip/segmentation/histogram.html

Limiarização

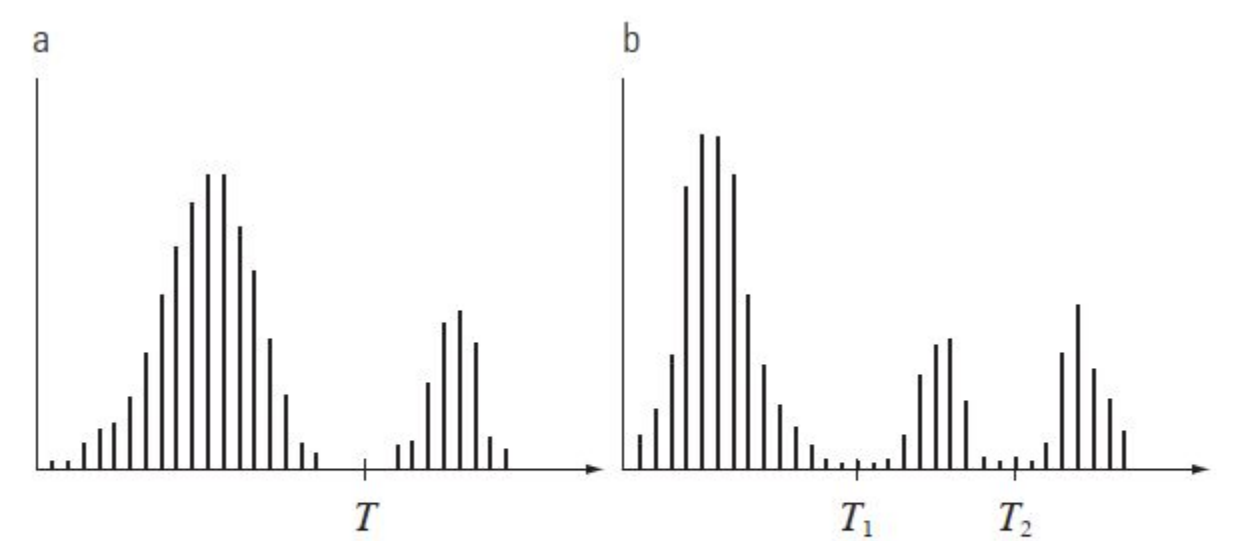
- 

Figura 10.35 Histogramas de intensidade que podem ser divididos (a) por um limiar único e (b) por limiares duplos.

Limiarização

- Principais fatores que afetam a limiarização baseada em histogramas:
  - A separação entre os picos;
  - O índice de ruído da imagem;
  - O tamanho relativo dos objetos e do fundo;
  - A uniformidade da fonte de iluminação;
  - A uniformidade das propriedades de reflexão da imagem.

Limiarização: Papel do Ruído

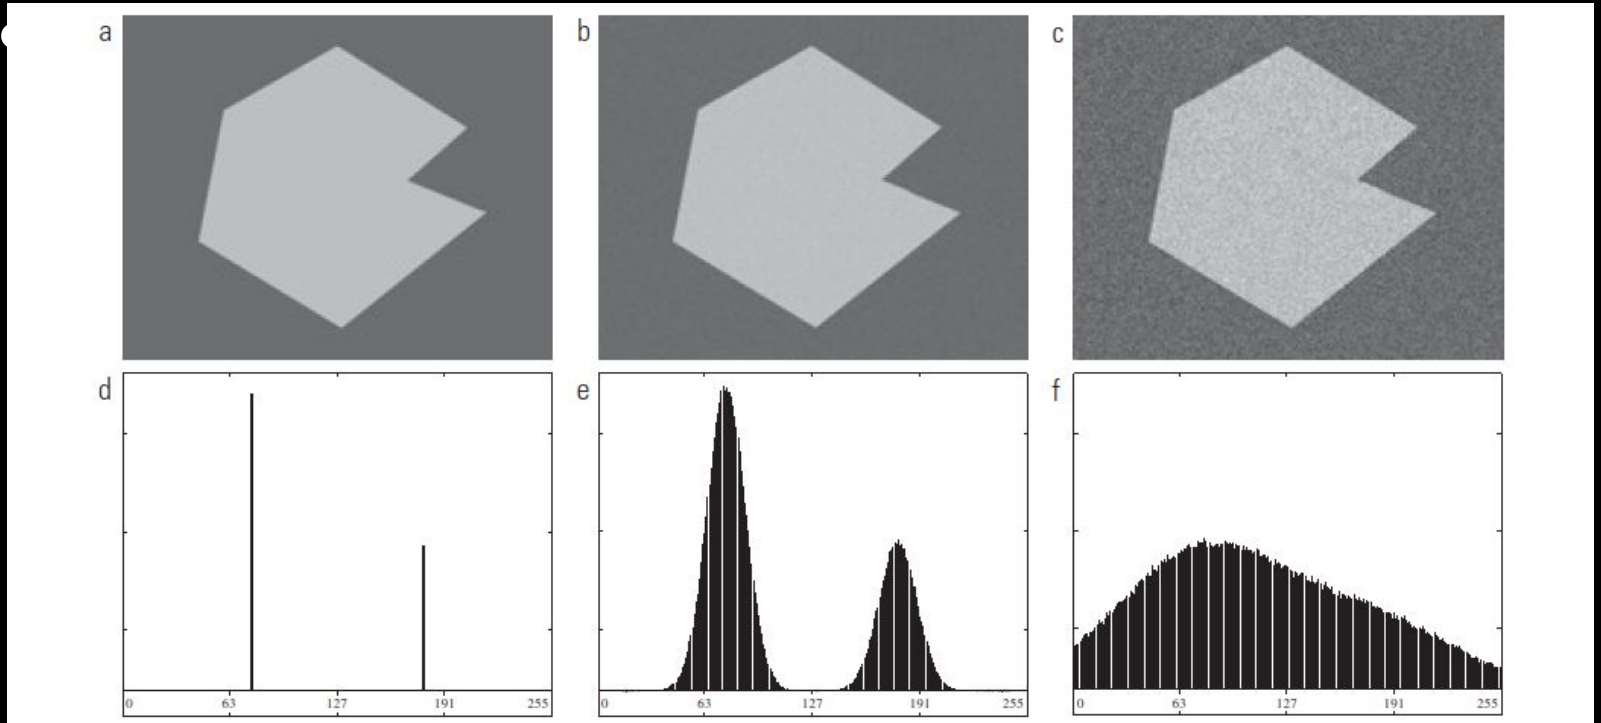


Figura 10.36 (a) Imagem de 8 bits livre de ruído. (b) Imagem com ruído gaussiano aditivo de média 0 e desvio padrão de 10 níveis de intensidade. (c) Imagem com ruído gaussiano aditivo de média 0 e desvio padrão de 50 níveis de intensidade. (d) a (f) Histogramas correspondentes.

Limiarização: Papel da Iluminação

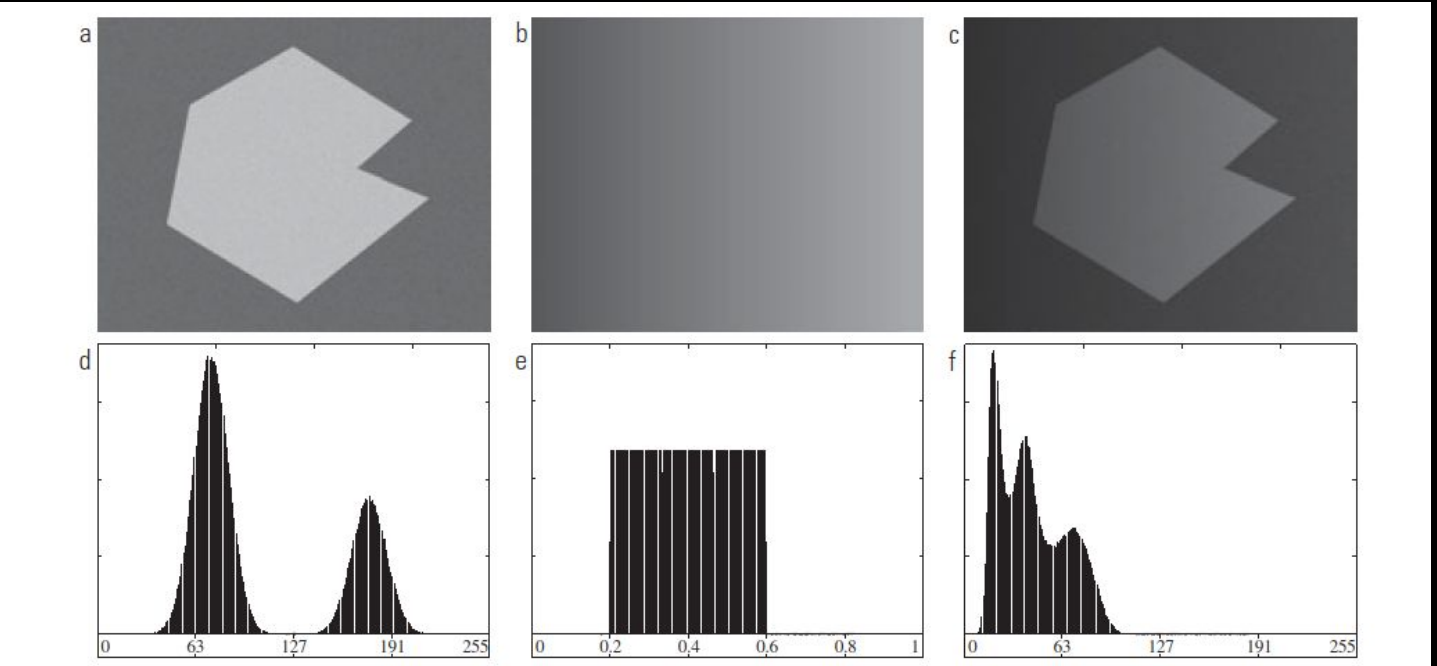
- 

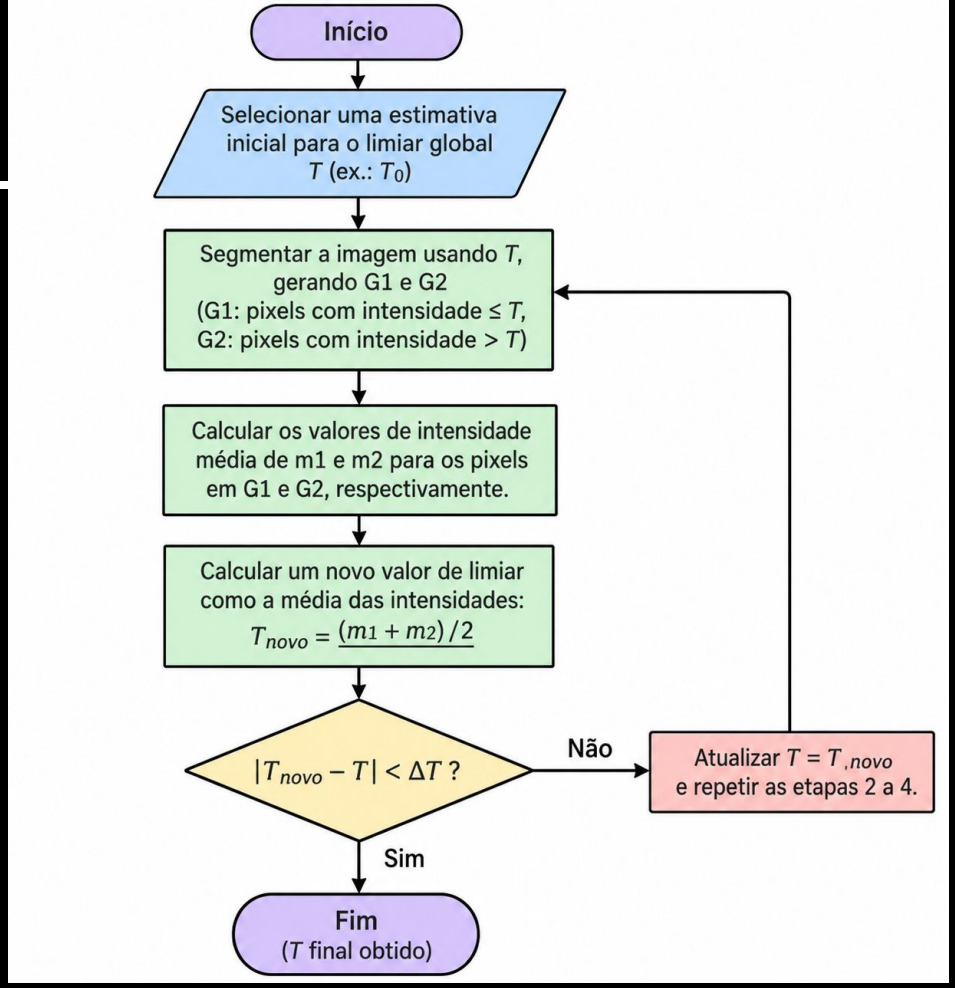
Figura 10.37 (a) Imagem ruidosa (b) Rampa de intensidade no intervalo [0,2, 0,6]. (c) Produto de (a) e (b). (d) a (f) Histogramas correspondentes.

Limiarização Global Simples

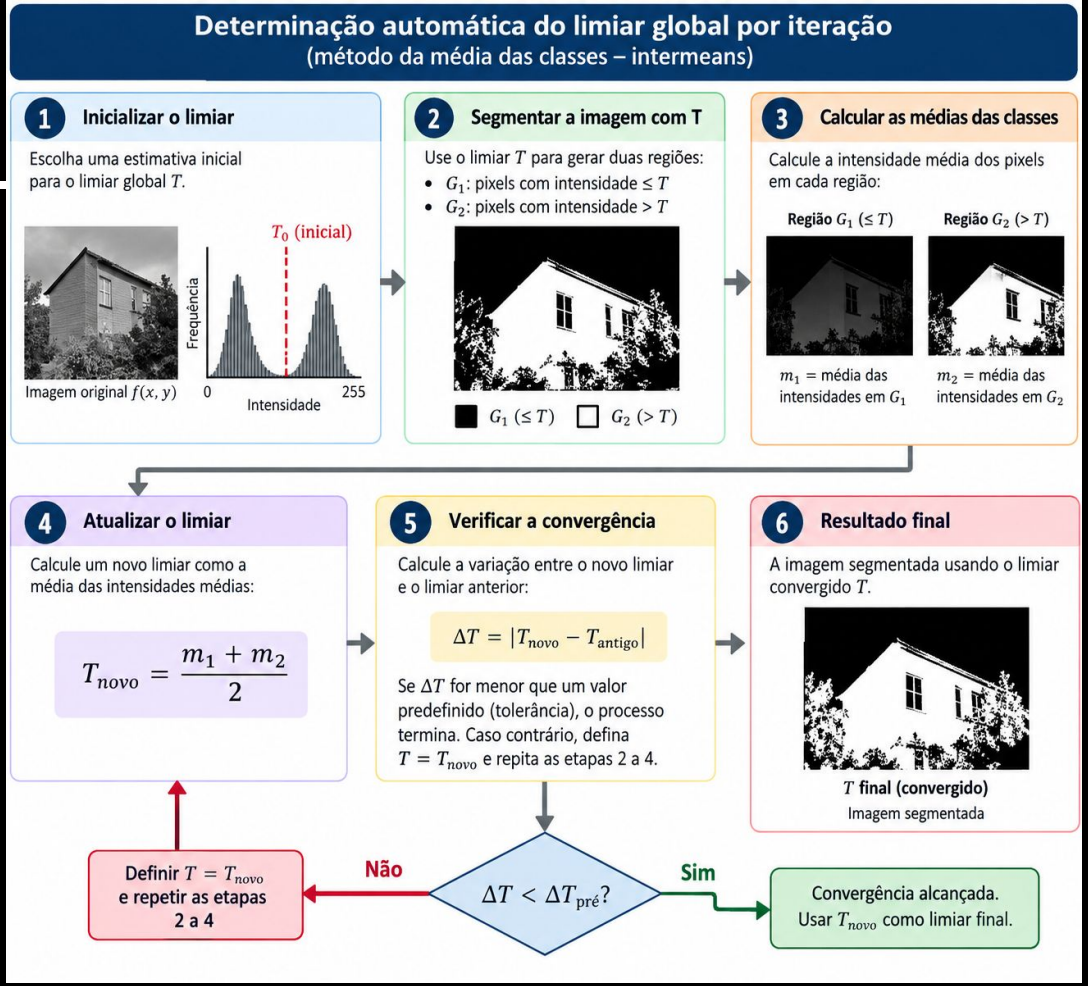
Limiarização: Global Simples

Algoritmo que determina o valor de T automaticamente.

1. Selecionar uma estimativa inicial para o limiar global, T.
2. Segmentar a imagem usando T, gerando G1 e G2.
3. Calcular os valores de intensidade média de m1 e m2 para os pixels em G1 e G2, respectivamente.
4. Calcular um novo valor de limiar como a média das intensidades.
5. Repita as etapas 2 a 4 até que a diferença entre os valores de T em iterações sucessivas seja menor que o parâmetro predefinido ΔT.



OPENAI. ChatGPT Images 2.5. Ferramenta de inteligência artificial generativa para criação de imagens. San Francisco: OpenAI, 2026. Disponível em: ChatGPT. Acesso em: 30 set. 2026.



OPENAI. ChatGPT Images 2.5. Ferramenta de inteligência artificial generativa para criação de imagens. San Francisco: OpenAI, 2026. Disponível em: ChatGPT. Acesso em: 30 set. 2026.

Limiarização: Global Simples

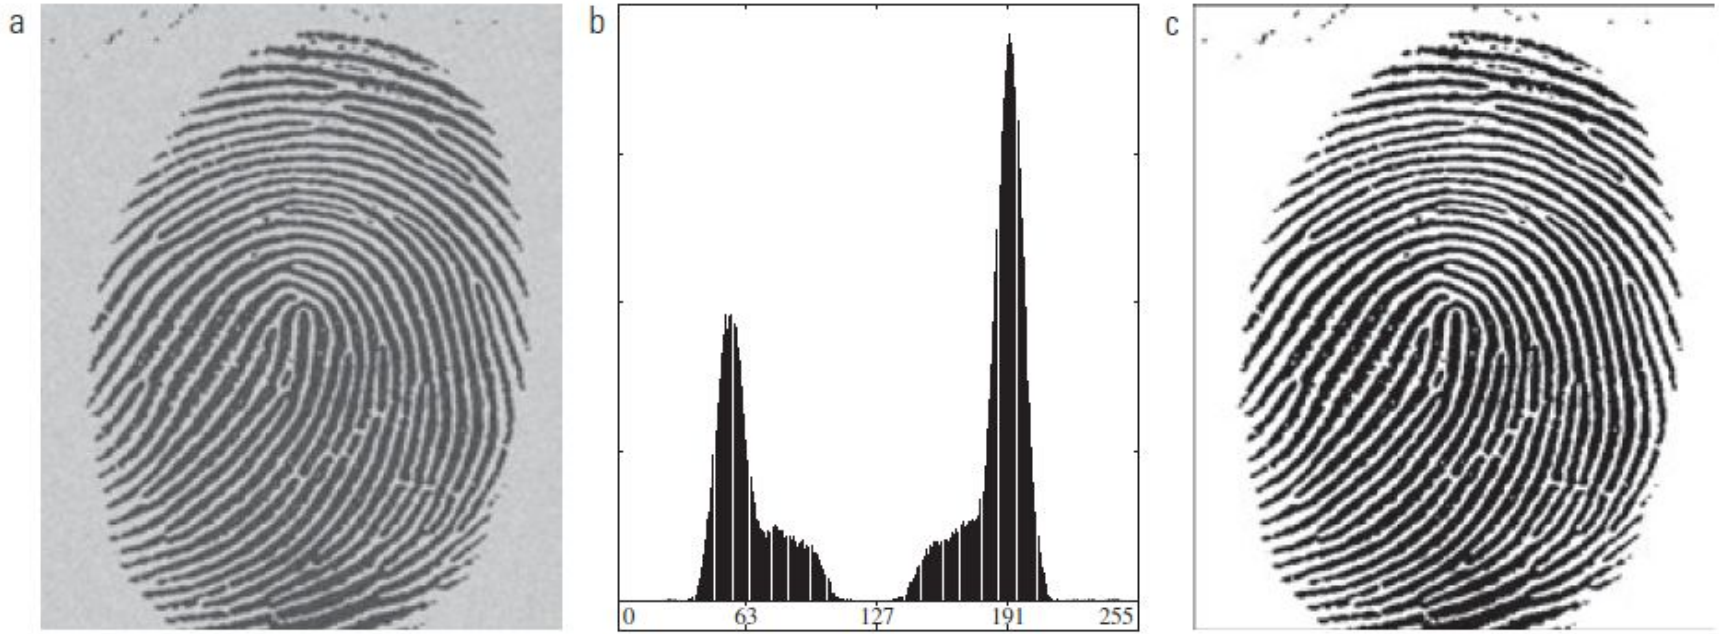
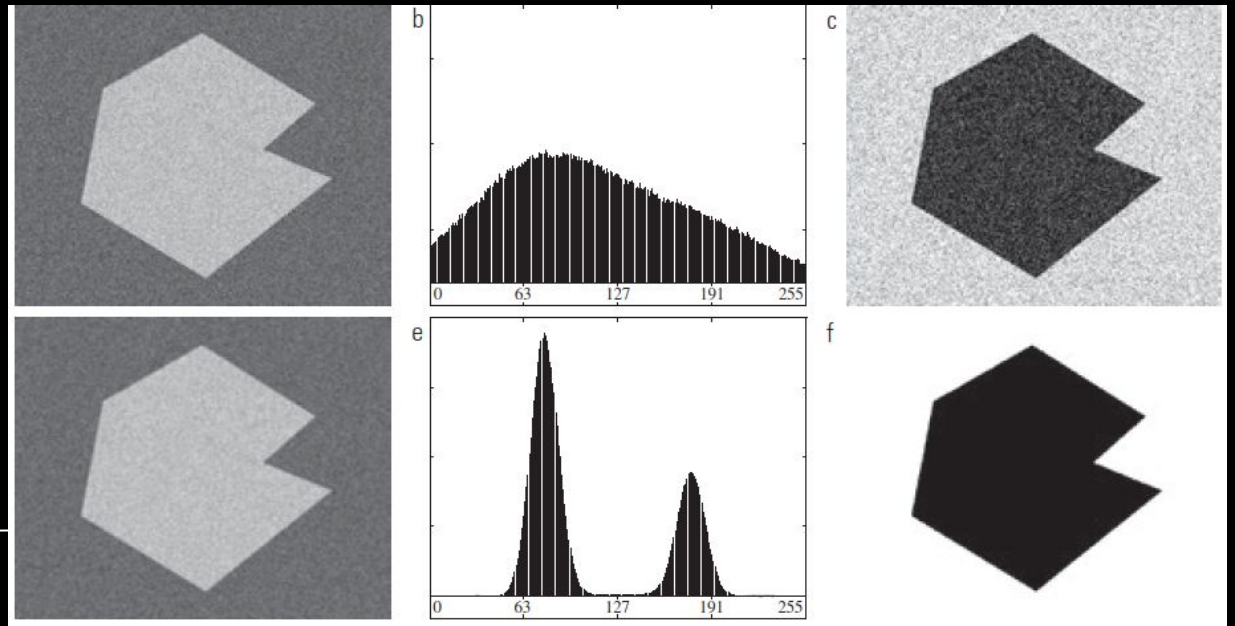


Figura 10.38 (a) Impressão digital ruidosa. (b) Histograma. (c) Segmentação resultante usando um limiar global (a moldura da imagem foi adicionada para maior clareza). (Original cortesia do National Institute of Standards and Technology.)

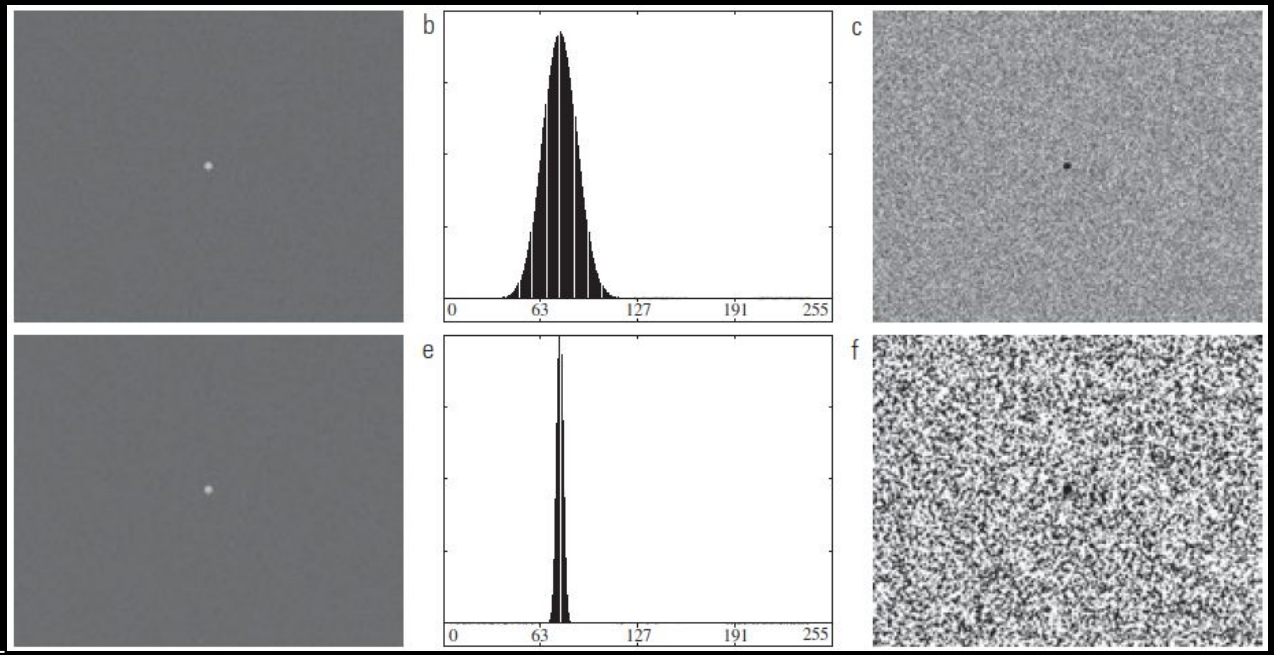
Limiarização: Global Simples

- Podemos melhorar a limiarização global aplicando técnicas de suavização.



Limiarização: Global Simples

- O histograma precisa apresentar duas modas.



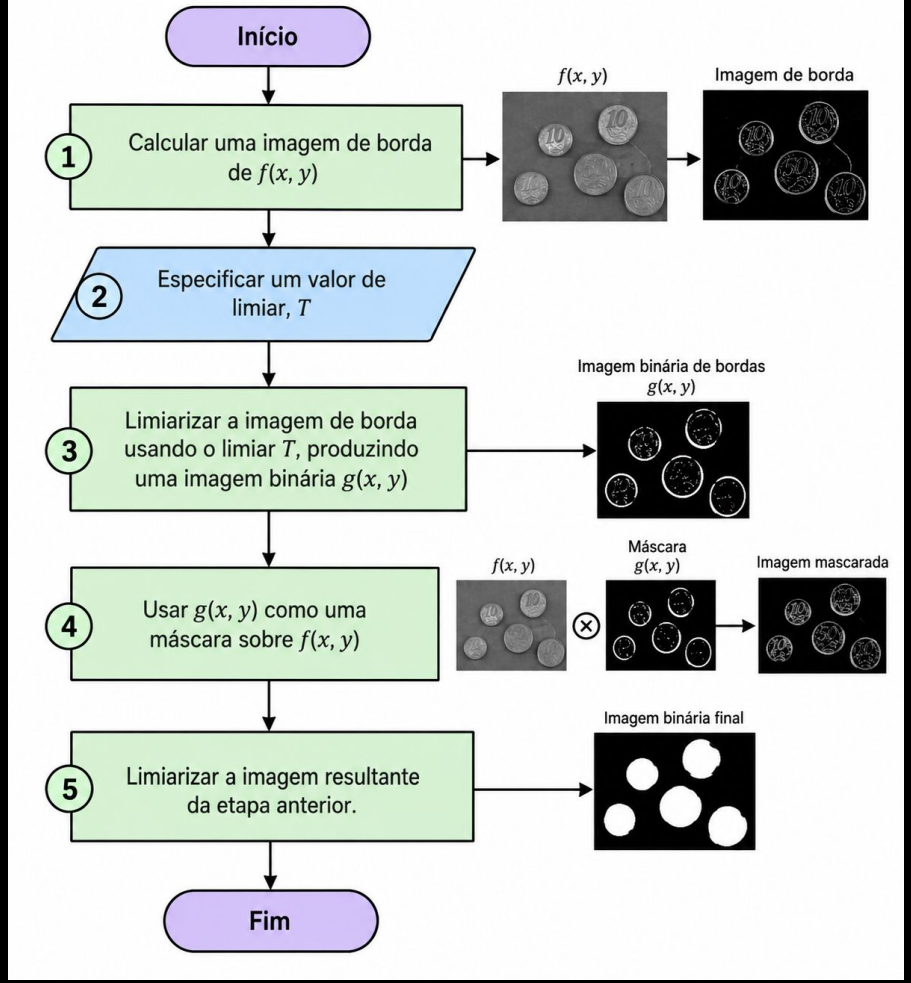
Limiarização: Global Simples

- Podemos melhorar a limiarização global aplicando técnicas de detecção de bordas.
  - Considerar somente os pixels que estão dentro ou perto das bordas entre os objetos e o fundo.

Limiarização: Global Simples com Bordas

Algoritmo

1. Calcular uma imagem de borda de f(x, y);
2. Especificar um valor de limiar, T;
3. Limiarizar a imagem a partir da Etapa 1, utilizando o limiar estabelecido na Etapa 2 para produzir uma imagem binária, g(x,y).
4. Use g(x,y) como uma máscara sobre f(x,y).
5. Limiarizar a imagem resultante da etapa anterior.



OPENAI. ChatGPT Images 2.5. Ferramenta de inteligência artificial generativa para criação de imagens. San Francisco: OpenAI, 2026. Disponível em: ChatGPT. Acesso em: 30 set. 2026.

Limiarização: Global Simples

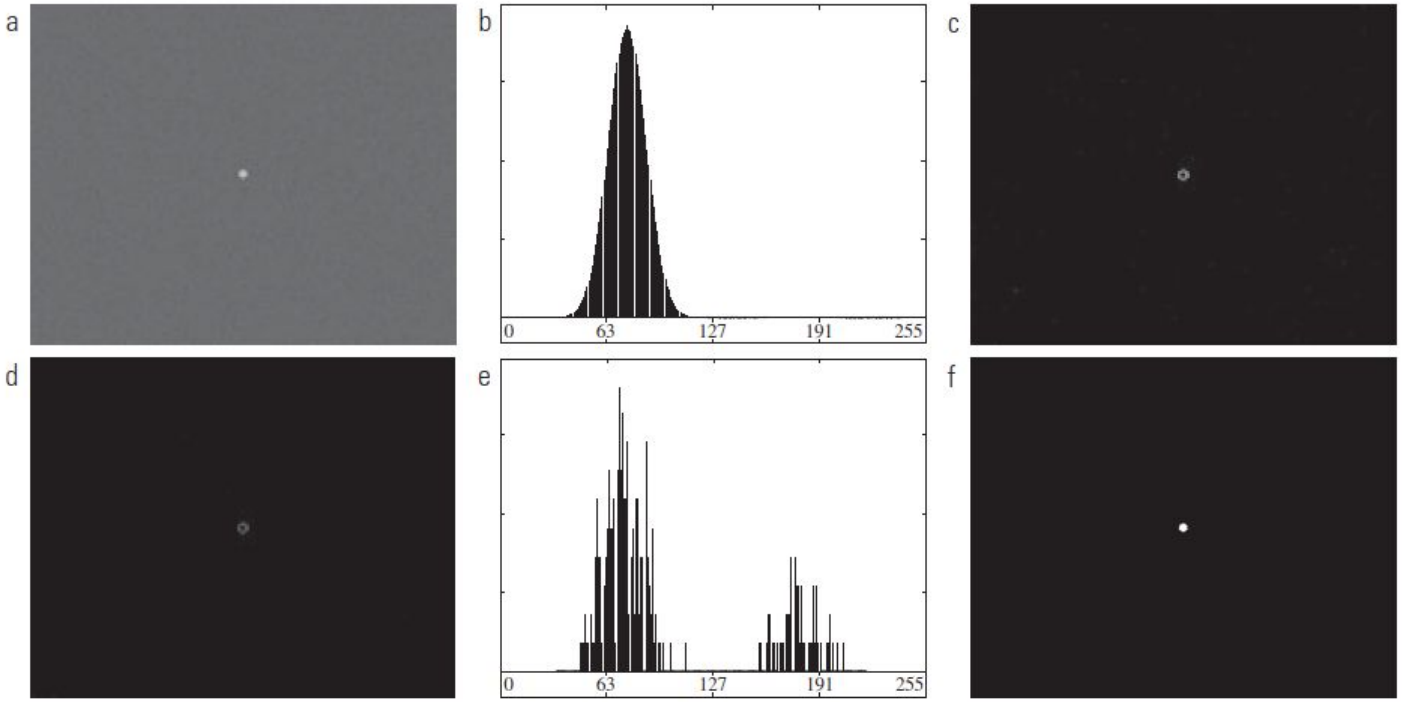


Figura 10.42 (a) Imagem ruidosa da Figura 10.41 e (b) seu histograma. (c) Imagem da magnitude do gradiente limiarizada no percentil 99,7. (d) Imagem formada como produto de (a) e (c). (e) Histograma dos pixels diferentes de zero na imagem em (d). (f) Resultado da segmentação da imagem (a) com o limiar de Otsu baseado no histograma de (e). O limiar foi de 134, que fica aproximadamente a meio caminho entre os picos no histograma.

Limiarização: Global Simples

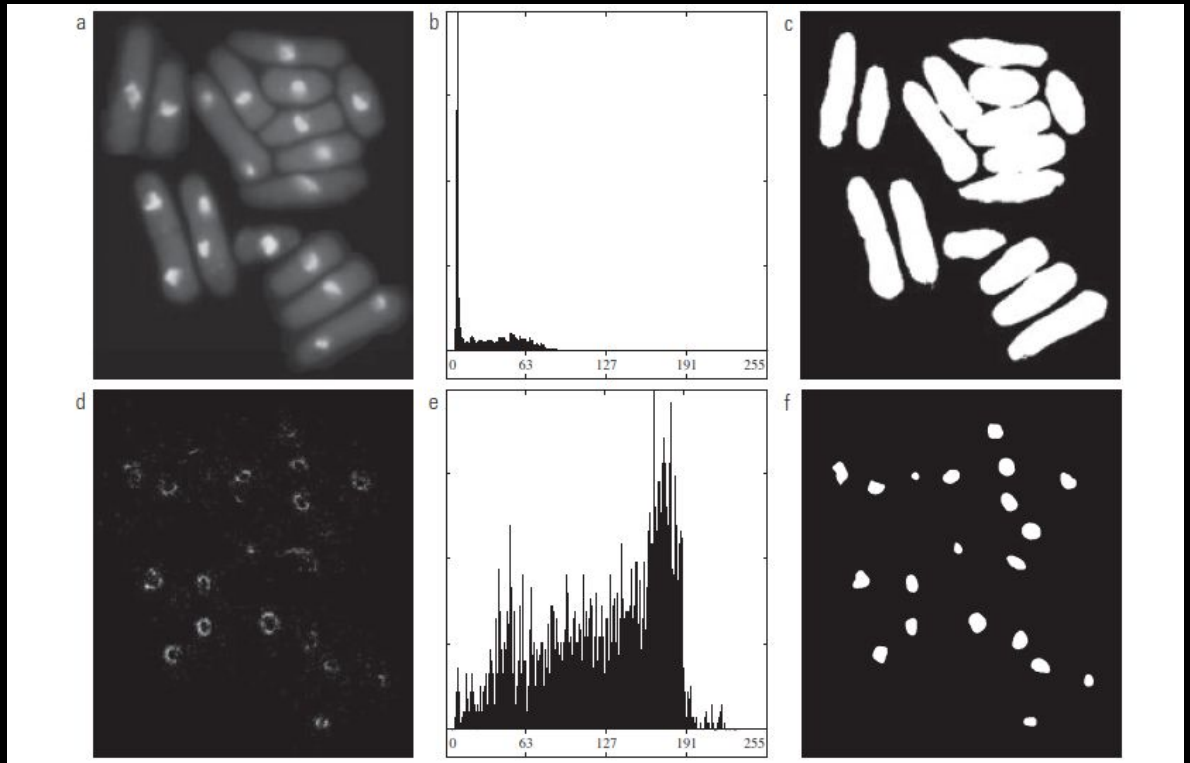


Figura 10.43 (a) Imagem das células de levedura. (b) Histograma de (a). (c) Segmentação de (a) com o método de Otsu, utilizando o histograma em (b). (d) Laplaciano absoluto limiarizado. (e) Histograma dos pixels diferentes de zero no produto de (a) e (d). (f) Imagem original limiarizada utilizando o método de Otsu baseado no histograma de (e). (Imagem original: cortesia da Professora Susan L. Forsburg, Universidade do Sul da Califórnia.)

Método de OTSU

Método de OTSU

- Aborda a limiarização do ponto de vista da teoria de decisão estatística.
  - Objetiva minimizar o erro médio da atribuição dos pixels para dois mais grupos (classes).
  - Função de decisão de Bayes
- Considera a função densidade de probabilidade de cada classe e a probabilidade que cada classe ocorre em uma dada aplicação.
  - Como obter a função de densidade de probabilidade?

Método de OTSU

- O método de OTSU é ótimo por maximizar a variância entre as classes.
  - O limiar escolhido deve distinguir as duas classes pela intensidade dos pixels.
    - O limiar que fornece a melhor separação das classes em termos da intensidade será o limiar ótimo.

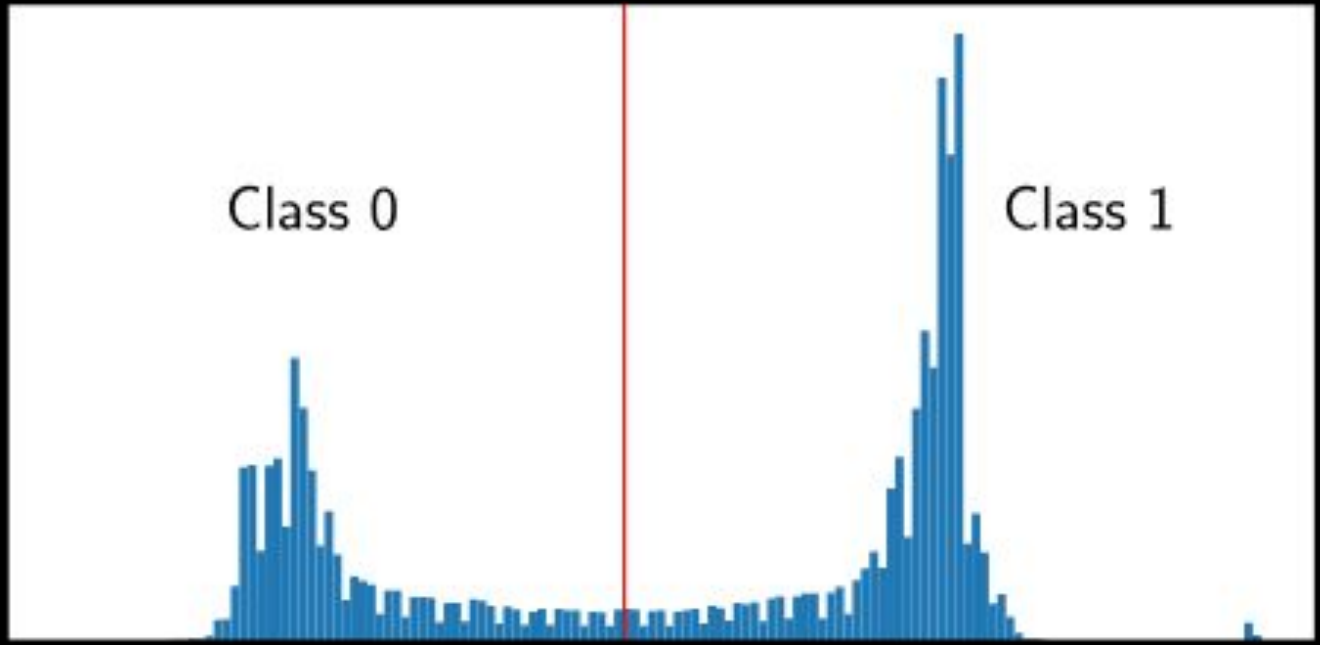
Método de OTSU

- Considere uma imagem de dimensões M x N, com L tons de cinza, isto é, valores no conjunto {0, 1, 2, …, L-2, L-1}.
- Do histograma normalizado obtemos: pi = ni / (MN)
  - Sabemos que para todo i, pi >= 0
  - Sabemos que a soma de todos os pi é 1

Método de OTSU

- Suponha um limiar k, tal que 0 < k < L-1
  - Obtemos duas classes c1 [0, k] e c2 [k+1, L-1]
- Logo, a probabilidade p1 da classe 1 será a soma das probabilidades de cada tom j considerando somente a classe 1 (tons de [0,k]).
  - Quantidade de vezes que o tom j aparece sobre a quantidade de pixel da classe p1.
- De modo análogo, temos a probabilidade p2 da classe 2, considerando o tons de [k+1, L-1].

Método de OTSU: Algoritmo



https://vincmazet.github.io/bip/segmentation/histogram.html

Método de OTSU

- Podemos determinar a média das intensidades de uma classe:

$$m_1(k) = \sum_{i=0}^{k} iP(i/c_1) = \sum_{i=0}^{k} iP(c_1/i)P(i)/P(c_1)$$

$$= \frac{1}{P_1(k)} \sum_{i=0}^{k} ip_i \qquad P(A/B) = P(B/A)P(A)/P(B)$$

Método de OTSU

- Podemos determinar a média cumulativa:

$$m(k) = \sum_{i=0}^{k} i\, p_i$$

- Podemos determinar a média global:

$$m_G = \sum_{i=0}^{L-1} i\, p_i$$

- Observe que:

$$P_1 m_1 + P_2 m_2 = m_G$$

$$P_1 + P_2 = 1$$

Método de OTSU

- Dado o desvio padrão entre as classes:

$$\sigma_B^2(k) = \frac{\left[m_G P_1(k) - m(k)\right]^2}{P_1(k)\left[1 - P_1(k)\right]}$$

- Desejamos encontrar o k* que maximize:

$$\sigma_B^2(k^*) = \max_{0 \le k \le L-1} \sigma_B^2(k)$$

Método de OTSU: Derivação

1. var = **P1 (m1 - mg)^2** + P2 (m2 - mg)^2
2. var = P1 [m1 - **P1 m1 - P2 m2**]^2 + P2 (m2 - mg)^2
3. var = P1 [**(1 - P1) m1** - P2 m2]^2 + P2 (m2 - mg)^2
4. var = P1 [**P2** m1 - P2 m2]^2 + P2 (m2 - mg)^2
5. var = P1 [**P2 (m1 - m2)**]^2 + P2 [P1 (m1 - m2)]^2
6. var = P1 P2^2 (m1 - m2)^2 + **P1^2 P2 (m1 - m2)^2**
7. var = **P1 P2 (m1 - m2)^2** (P1 + P2)
8. var = P1 P2 (m1 - m2)^2

Método de OTSU

- var = P1 P2 (m1 - m2)^2
- P1 P2 representa o equilíbrio entre os picos dos histogramas (entre as classes).
- (m1 - m2)^2 representa a separação entre os histogramas (entre as classes).

Método de OTSU

- Uma vez que k* é determinado, a limiarização é definida como:

$$g(x,y) = \begin{cases} 1 & \text{if } f(x,y) > k^* \\ 0 & \text{if } f(x,y) \leq k^* \end{cases}$$

- Observe que todas as informações necessárias são obtidas do histograma da imagem.

Método de OTSU: Algoritmo

1. Determine o histograma da imagem e as probabilidades para cada nível de cinza.
2. Determine as probabilidade acumuladas de p1.
3. Para todos os valores possíveis de limiares k [1,L-2]:

$$\sigma_B^2(k) = \frac{\left[m_G P_1(k) - m(k)\right]^2}{P_1(k)\left[1 - P_1(k)\right]}$$

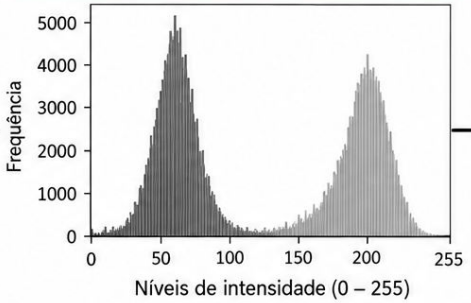
4. Retorne:

$$\sigma_B^2\left(k^*\right) = \max_{0 \le k \le L-1} \sigma_B^2(k)$$

1 Imagem de entrada
$f(x, y)$



2 Calcular o histograma e as probabilidades

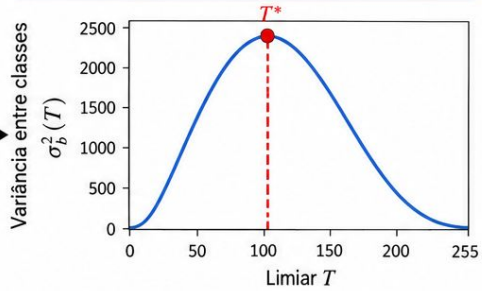


$$p(i) = \frac{n_i}{N}$$

n_i : número de pixels com intensidade i

N : número total de pixels

3 Calcular a variância entre classes para cada limiar



$$\sigma_b^2(T) = \omega_0(T)\omega_1(T)[\mu_0(T) - \mu_1(T)]^2$$

$\omega_0(T), \omega_1(T)$: probabilidades das classes

$\mu_0(T), \mu_1(T)$: médias das classes

T^* : limiar que maximiza $\sigma_b^2(T)$

4 Selecionar o limiar ótimo
T^*

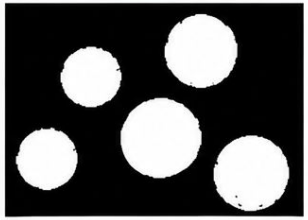
$$T^* = \arg\max_{0 \le T \le 255} \sigma_b^2(T)$$

(máximo da variância entre classes)

5 Limiarizar a imagem usando T^*

$$g(x, y) = \begin{cases} 1, & \text{se } f(x, y) \ge T^* \\ 0, & \text{se } f(x, y) < T^* \end{cases}$$

6 Imagem binária resultante
$g(x, y)$



OPENAI. ChatGPT Images 2.5. Ferramenta de inteligência artificial generativa para criação de imagens. San Francisco: OpenAI, 2026. Disponível em: ChatGPT. Acesso em: 30 set. 2026.

Limiarização automática: Método de Otsu

Seleção automática do limiar global por análise do histograma

1 Obter o histograma da imagem



Imagem original $f(x, y)$



O método de Otsu assume que o histograma pode ser separado em duas classes: **fundo** e **objeto**.

2 Testar limiares candidatos



Para cada T, calculam-se as probabilidades e médias das duas classes.

$$\omega_1(T) = \sum_{i=0}^{T} p(i) \qquad \mu_1(T) = \frac{\sum_{i=0}^{T} ip(i)}{\omega_1(T)}$$

$$\omega_2(T) = \sum_{i=T+1}^{L-1} p(i) \qquad \mu_2(T) = \sum_{i=T+1}^{L-1} \frac{ip(i)}{\omega_2(T)}$$

3 Calcular a variância entre as classes

Variância entre classes (separação das classes)

$$\sigma_b^2(T) = \omega_1(T)\omega_2(T)\left[\mu_1(T) - \mu_2(T)\right]^2$$

$\omega_1(T)$ e $\omega_2(T)$: probabilidades das duas classes

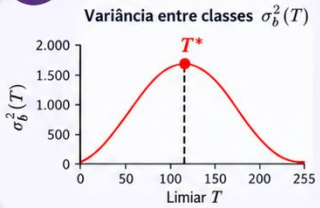
$\mu_1(T)$ e $\mu_2(T)$: médias das duas classes

Para cada limiar T, calcula-se a variância **entre** as classes.

Quanto maior $\sigma_b^2(T)$, melhor a separação entre fundo e objeto.

O método de Otsu procura o limiar que **maximiza** esse critério.

4 Escolher o limiar ótimo T^*



$$T^* = \arg\max_T \sigma_b^2(T)$$

T^* é o limiar que melhor separa fundo e objeto.

5 Segmentar a imagem



Imagem original $f(x, y)$



Resultado segmentado $g(x, y)$

Aplicando T^* à imagem, obtém-se a segmentação final.

$$g(x,y) = \begin{cases} 1, & \text{se } f(x,y) > T^*, \\ 0, & \text{caso contrário.} \end{cases}$$

Resumo: calcular histograma → avaliar limiares → medir separação entre classes → escolher T^* → segmentar a imagem.

OPENAI. ChatGPT Images 2.5. Ferramenta de inteligência artificial generativa para criação de imagens. San Francisco: OpenAI, 2026. Disponível em: ChatGPT. Acesso em: 30 set. 2026.

Método de OTSU: Comentários

- Resultado será ótimo quando o histograma da imagem for bimodal com picos bem separados.
- Sofre as mesmas limitações dos métodos de limiarização global: sensível à:
  - Ruídos extremos.
  - Pequenos objetos.
  - Variação de iluminação.

Múltipla Limiarização

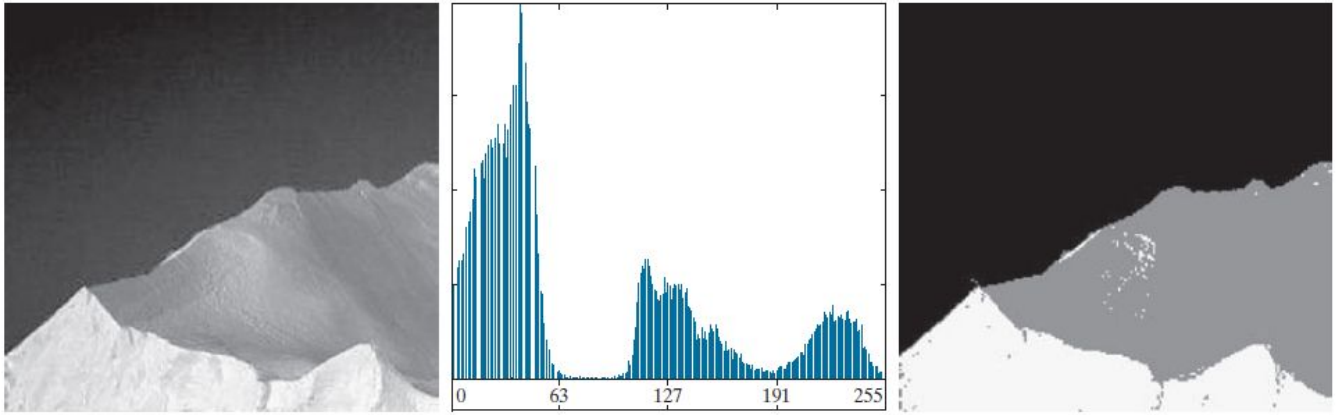
Múltiplos Limiares

- Consiste em tratar mais de duas classes.
- Exemplo para três classes:

$$g(x,y) = \begin{cases} a & \text{if } f(x,y) \le k_1^* \\ b & \text{if } k_1^* < f(x,y) \le k_2^* \\ c & \text{if } f(x,y) > k_2^* \end{cases}$$

Múltiplos Limiares

- O método de OTSU pode ser estendido para lidar com múltiplas classes.



a b c

FIGURE 10.42 (a) Image of an iceberg. (b) Histogram. (c) Image segmented into three regions using dual Otsu thresholds. (Original image courtesy of NOAA.)

Limiarização Variável

Limiarização Variável

- Particionamento da Imagem.
  - Subdivisão da imagem em retângulos que se sobrepõem.
  - Essa abordagem é utilizada para compensar a não uniformidade de iluminação e/ou a refletância.
  - Os retângulos escolhidos são suficientemente pequenos para que a iluminação de cada um seja o mais uniforme possível.
  - Funciona bem quando os objetos de interesse e o fundo ocupam regiões de tamanho razoavelmente comparável.

Particionamento da imagem para segmentação local

Subdivisão em retângulos sobrepostos para compensar iluminação não uniforme

1 Imagem com iluminação não uniforme



$f(x, y)$

Variações de iluminação e/ou refletância dificultam o uso de um único limiar global.

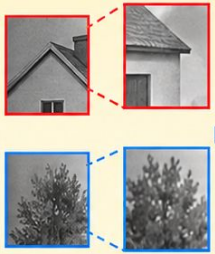
2 Subdividir em retângulos sobrepostos



A imagem é particionada em regiões locais.

Os retângulos se sobrepõem para reduzir descontinuidades entre regiões vizinhas.

3 Assumir uniformidade local



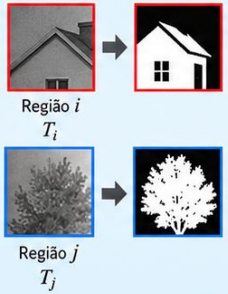
Cada retângulo é suficientemente pequeno para que a iluminação local seja quase uniforme.

Isso facilita a separação entre objeto e fundo em cada região.

4 Segmentar cada retângulo localmente

Aplicar um critério de limiarização em cada região.

Limiar local T_i



Região i
T_i

Região j
T_j

Cada subimagem pode usar um limiar próprio.

5 Combinar os resultados



As segmentações locais são reunidas para formar o resultado final.

A abordagem funciona bem quando objeto e fundo ocupam regiões de tamanho razoavelmente comparável.

Resumo

Dividir a imagem em retângulos sobrepostos → Assumir uniformidade local → Limiarizar cada região → Combinar os resultados

Resumo: dividir a imagem em retângulos sobrepostos → assumir uniformidade local → limiarizar cada região → combinar os resultados.

Vantagem

Vantagem: compensa não **uniformidade** de iluminação.

Indicado quando

Indicado quando objeto e fundo têm tamanhos comparáveis nas regiões locais.

OPENAI. ChatGPT Images 2.5. Ferramenta de inteligência artificial generativa para criação de imagens. San Francisco: OpenAI, 2026. Disponível em: ChatGPT. Acesso em: 30 set. 2026.

Limiarização Variável

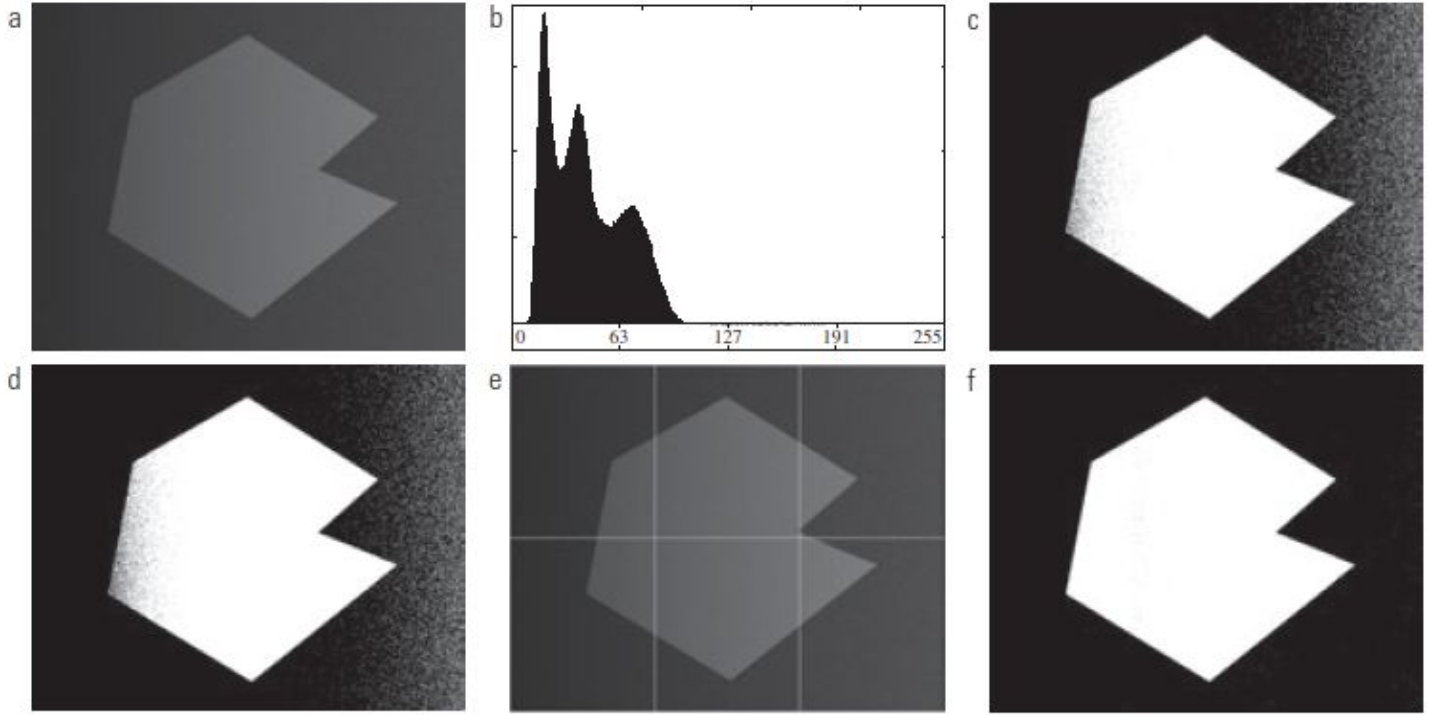


Figura 10.46 (a) Imagem ruidosa e sombreada. (b) Seu histograma. (c) Segmentação de (a) utilizando o algoritmo iterativo global da Seção 10.3.2. (d) Resultado obtido utilizando o método de Otsu. (e) Imagem subdividida em seis subimagens. (f) Resultado da aplicação do método de Otsu individualmente para cada subimagem.

Limiarização Variável

- Uso de propriedades locais.
  - Calcular um limiar para cada ponto, (x, y), da imagem com base em uma ou mais propriedades especificadas que são calculadas em sua vizinhança.
    - Processamento eficiente em hardware.

$$Q(\sigma_{xy}, m_{xy}) = \begin{cases} \text{verdadeiro} & \text{se } f(x,y) > a\sigma_{xy} \text{ E } f(x,y) > bm_{xy} \\ \text{falso} & \text{caso contrário} \end{cases}$$

Limiarização Variável

- Os valores a = 30 e b = 1,5 foram utilizados.
- Vizinhança 5 x 5.

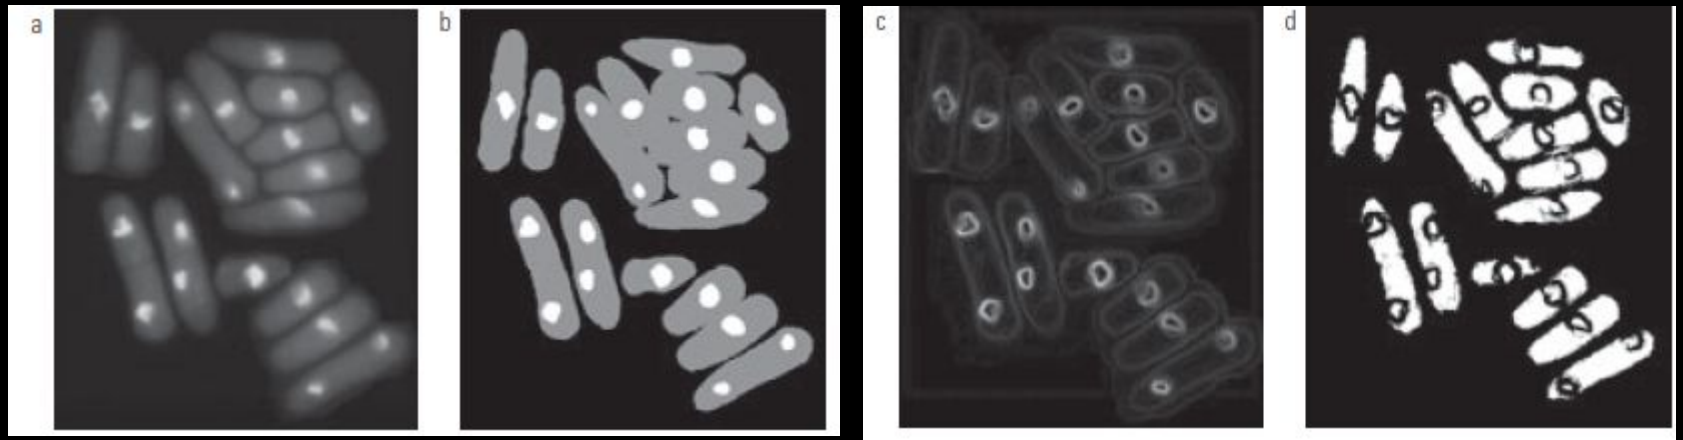


Figura 10.48 (a) Imagem da Figura 10.43. (b) Imagem segmentada usando a abordagem de limiarização dupla discutida na Seção 10.3.6. (c) Imagem dos desvios padrão locais. (d) Resultado obtido utilizando a limiarização local.

Limiarização no OpenCV

Limiarização no OpenCV

```
# limiarização fixa pelo valor thresh
retval, img = cv2.threshold(src,thresh,maxval,type)


# cv2.THRESH_BINARY
        # Pixel = maxval se > thresh, senão 0
# cv2.THRESH_TRUNC
        # Pixel = thresh se > thresh, senão valor original
# cv2.THRESH_TOZERO
        # Pixel = valor original se > thresh, senão 0
```

Limiarização no OpenCV

```
# limiarização automática por OTSU

# Usados com cv2.THRESH_BINARY e passando thresh = 0.


retval, img = cv2.threshold(img, 0, 255, cv2.THRESH_BINARY + cv2.THRESH_OTSU)
```

Limiarização no OpenCV

```
# limiarização adaptativa

img = cv2.adaptiveThreshold(src, maxValue, adaptiveMethod, type, blockSize, C)

# cv2.ADAPTIVE_THRESH_MEAN_C
        # Média dos vizinhos menos C
# cv2.ADAPTIVE_THRESH_GAUSSIAN_C
        # Média ponderada (Gaussiana) dos vizinhos menos C
```

Exercícios

Exercício

- Determina um processo para limiarização de cada uma das imagens e determina se a limiarização funcionou ou não:
  - a) digital.png
  - b) bolhas.png
  - c) pac.png
  - d) pac2.png
  - e) star.png
  - f) bacilos.png (estrutura alongada)
  - g) bacilos.png (esferas claras)
  - h) bacilos.png (estrutura alongada e esferas juntas)
  - i) montanha.png (três regiões)

Resumo

Resumo

- Limiarização Global
  - Algoritmo Iterativo
  - Aplicação de Bordas
  - Aplicação de Suavização
- Método de OTSU
  - Algoritmo
  - Limitações
- Limiarização Variável
  - Particionamento e Propriedades Locais

Dúvidas?